

Online Retail Veri Seti ile E-Ticaret Müşteri Davranışı Analizi ve Müşteri Segmentasyonu



Ders: Veri Bilimi / Final Projesi
Öğrenci Adı Soyadı: Rüveyda Durmuş
Öğrenci Numarası: 1316200065
Teslim Tarihi: 3 Temmuz 2026
Veri Seti: UCI Online Retail Dataset
Tema: E-ticaret & Müşteri Davranışı

1. Problem Tanımı ve Amaç

Bu çalışmanın amacı, gerçek bir e-ticaret işlem veri seti kullanılarak veri bilimi iş akışının temel adımlarını uygulamaktır. Çalışmada veri yükleme, veri temizleme, keşifsel veri analizi, görselleştirme ve temel modelleme aşamaları gerçekleştirilmiştir.

Proje kapsamında UCI Machine Learning Repository üzerinde yer alan **Online Retail** veri seti kullanılmıştır. Veri seti, Birleşik Krallık merkezli bir çevrimiçi perakende firmasının satış işlemlerini içermektedir. Veri setinde fatura numarası, ürün kodu, ürün açıklaması, ürün adedi, fatura tarihi, birim fiyat, müşteri numarası ve ülke bilgisi bulunmaktadır.

Bu çalışma ile aşağıdaki araştırma sorularına cevap aranmıştır:

1. Ülkelerin toplam satış gelirine etkisi nasıldır?
2. Satış gelirleri zaman içinde nasıl değişmektedir?
3. Sipariş tutarlarının dağılımı nasıldır?
4. Müşteriler satın alma davranışlarına göre segmentlere ayrılabilir mi?

Bu sorular doğrultusunda e-ticaret müşteri davranışları hem görsel analizlerle hem de temel bir kümeleme modeliyle incelenmiştir.

2. Veri Seti ve Kaynağı

Çalışmada kullanılan veri seti **Online Retail Dataset** olarak adlandırılmaktadır. Veri seti UCI Machine Learning Repository üzerinden sağlanmıştır. Veri, 2010 ve 2011 yılları arasındaki çevrimiçi perakende işlemlerini içermektedir.

Veri setinde yer alan temel değişkenler aşağıdaki gibidir:

Değişken	Açıklama
InvoiceNo	Fatura / sipariş numarası
StockCode	Ürün kodu
Description	Ürün açıklaması
Quantity	Satılan ürün adedi
InvoiceDate	Fatura tarihi
UnitPrice	Ürün birim fiyatı
CustomerID	Müşteri numarası
Country	Müşterinin bulunduğu ülke

Bu veri setinin seçilme nedeni, e-ticaret müşteri davranışını analiz etmek için gerçek işlem verileri içermesi ve veri bilimi iş akışının temel adımlarına uygun olmasıdır. Veri setinde eksik değerler, aykırı değerler, tarih dönüşümleri, gelir hesaplama ve müşteri bazlı analizler yapılabildiği için proje kapsamına uygundur.

Veri Kaynağı: UCI Machine Learning Repository – Online Retail Dataset
Lisans: Creative Commons Attribution 4.0 International (CC BY 4.0)

3. Yöntem

Çalışmada Python programlama dili ve Jupyter/Colab notebook ortamı kullanılmıştır. Analiz sürecinde temel olarak şu kütüphanelerden yararlanılmıştır:

- pandas
- numpy
- matplotlib
- seaborn
- scikit-learn

Veri bilimi iş akışı aşağıdaki adımlardan oluşmuştur:

1. Veri setinin yüklenmesi
2. Veri yapısının incelenmesi
3. Eksik değer analizi
4. Veri temizleme
5. Tip dönüşümleri
6. Yeni değişken oluşturma
7. Keşifsel veri analizi
8. Görselleştirme
9. RFM analizi
10. K-Means ile müşteri segmentasyonu

4. Veri Temizleme Süreci

İlk aşamada veri seti pandas kütüphanesi ile yüklenmiş ve genel yapısı incelenmiştir. `df.info()`, `df.head()`, `df.describe()` ve `df.isnull().sum()` gibi fonksiyonlar kullanılarak veri setindeki kolonlar, veri tipleri, eksik değerler ve temel istatistikler analiz edilmiştir.

Veri temizleme aşamasında aşağıdaki işlemler yapılmıştır:

- InvoiceDate değişkeni tarih formatına dönüştürülmüştür.
- CustomerID alanında eksik değer bulunan kayıtlar müşteri segmentasyonu için uygun olmadığı için RFM analizi öncesinde çıkarılmıştır.
- Quantity ve UnitPrice değişkenlerinde sıfır veya negatif değerler kontrol edilmiştir.
- İptal işlemlerini temsil eden negatif miktarlar analiz kapsamına göre değerlendirilmiştir.
- Satır bazlı toplam gelir için yeni bir TotalPrice değişkeni oluşturulmuştur.

Toplam gelir değişkeni şu şekilde hesaplanmıştır:

`TotalPrice = Quantity × UnitPrice`

Bu deęişken, lke bazlı gelir analizi, zaman bazlı gelir analizi ve mřterisi bazlı harcama analizlerinde kullanılmıřtır.


Eksik deęerler ve aykırı deęerler incelenirken veri kaybını en aza indirmek iin doęrudan silme iřlemi yerine iř baęlamına gre deęerlendirme yapılmıřtır. zellikle e-ticaret verilerinde yksek adetli veya yksek tutarlı sipariřlerin her zaman hata olmayabileceęi dikkate alınmıřtır.

5. Keřifsel Veri Analizi Bulguları

Keřifsel veri analizi ařamasında veri setinin genel yapısı, satıřların lkelere gre daęılımı, zaman iindeki gelir deęiřimi, sipariř tutarlarının daęılımı ve sayısal deęiřkenler arasındaki iliřkiler incelenmiřtir.

5.1 lkelerin Toplam Gelire Etkisi


İlk arařtırma sorusu, lkelerin toplam satıř gelirine etkisini incelemeye yneliktir. Bu amala lke bazında toplam TotalPrice deęerleri hesaplanmıř ve en yksek gelir getiren lkeler grselleřtirilmiřtir.



Grafik incelendięinde, toplam gelirin nemli bir kısmının **United Kingdom** kaynaklı olduęu grlmektedir. Bu durum, veri setinin Birleřik Krallık merkezli bir online perakende firmasına ait olmasıyla uyumludur. United Kingdom dıřındaki lkelerde gelir katkısı daha sınırlı kalmaktadır. Bu nedenle řirketin ana pazarının Birleřik Krallık olduęu, dięer lkelerin ise daha dřk hacimli dıř pazarlar olarak deęerlendirilebileceęi sonucuna ulařılmıřtır.

5.2 Satıř Gelirlerinin Zaman İindeki Deęiřimi

İkinci arařtırma sorusunda satıř gelirlerinin zaman iinde nasıl deęiřtięi incelenmiřtir. Bunun iin InvoiceDate deęiřkeninden ay bilgisi ıkarılmıř ve her ay iin toplam satıř geliri hesaplanmıřtır.




Çizgi grafik, satış gelirlerinin aylara göre dalgalandığını göstermektedir. Bazı aylarda satış gelirlerinde artış, bazı aylarda ise düşüş gözlemlenmiştir. E-ticaret bağlamında bu tür dalgalanmalar kampanya dönemleri, sezonluk alışveriş alışkanlıkları, yıl sonu talep artışı veya müşteri davranışındaki dönemsel değişimlerle ilişkili olabilir.


Zaman bazlı analiz, satışların yalnızca toplam miktar olarak değil, dönemsel değişim açısından da değerlendirilmesini sağlamıştır. Bu sayede hangi dönemlerde satış performansının daha yüksek olduğu gözlemlenmiştir.

5.3 Sipariş Tutarlarının Dağılımı

Üçüncü araştırma sorusu, sipariş tutarlarının dağılımını incelemeye yöneliktir. Bu analiz için önce her fatura numarası bazında toplam sipariş tutarı hesaplanmıştır. Daha sonra sipariş tutarlarının dağılımı histogram ve boxplot grafikleri ile incelenmiştir.



Histogram grafiği, siparişlerin büyük çoğunluğunun düşük ve orta tutarlı siparişlerden oluştuğunu göstermektedir. Dağılımın sağa çarpık olduğu görülmektedir. Bu durum, az sayıda çok yüksek tutarlı siparişin bulunduğunu göstermektedir.




Boxplot grafiğinde de bazı yüksek tutarlı siparişlerin aykırı değer olarak öne çıktığı görülmektedir. E-ticaret verilerinde bu durum beklenen bir sonuçtur. Çünkü bazı müşteriler düşük tutarlı alışveriş yaparken, bazı müşteriler veya kurumsal alıcılar daha yüksek tutarlı siparişler verebilir.

Bu nedenle aykırı değerler doğrudan veri hatası olarak kabul edilmemiştir. Ancak bu değerlerin ortalama ve toplam gelir gibi istatistikleri etkileyebileceği dikkate alınmıştır.

5.4 Ülkelere Göre Sipariş Tutarı Dağılımı

Ülkeler bazında sipariş tutarlarının dağılımını incelemek için ilk 6 ülke üzerinde boxplot grafiği oluşturulmuştur.



Grafik incelendiğinde, United Kingdom ülkesinde çok sayıda sipariş bulunduğu ve bazı siparişlerin oldukça yüksek tutarlara ulaştığı görülmektedir. United Kingdom'daki yüksek aykırı değerler, grafiğin y eksenini ölçeğini genişletmiş ve diğer ülkelerdeki dağılımların daha sıkışık görünmesine neden olmuştur.

Netherlands için sipariş tutarlarının diğer bazı ülkelere göre daha geniş bir aralıkta dağıldığı görülmektedir. France, Germany, Australia ve EIRE ülkelerinde ise siparişlerin büyük çoğunluğu daha düşük tutar aralıklarında yoğunlaşmaktadır. Bu bulgu, ülkeler arasında müşteri harcama davranışlarının farklılık gösterebildiğini ortaya koymaktadır.

5. Modelleme: RFM Analizi ve K-Means Kümeleme

Çalışmanın modelleme aşamasında müşteri segmentasyonu yapılmıştır. Araştırma sorusu şu şekilde belirlenmiştir:

Müşteriler satın alma davranışlarına göre segmentlere ayrılabilir mi?

Bu soruya cevap vermek için RFM analizi ve K-Means kümeleme yöntemi kullanılmıştır.

RFM analizi üç temel müşteri davranışı değişkeninden oluşmaktadır:

Recency: Müşterinin son alışverişinden bu yana geçen gün sayısı

Frequency: Müşterinin toplam sipariş sayısı

Monetary: Müşterinin toplam harcama tutarı


Müşteri bazında bu üç değişken hesaplandıktan sonra modelleme için veri hazırlanmıştır. K-Means algoritması mesafe tabanlı bir yöntem olduğu için değişkenler standartlaştırılmıştır. Ayrıca Frequency ve Monetary değişkenlerinde yüksek çarpıklık olabileceği için log dönüşümü uygulanmıştır.

Küme sayısını belirlemek için Elbow Method ve Silhouette Score sonuçları incelenmiştir.

Proje kapsamında müşteriler 2 farklı kümeye ayrılmıştır.

Değerli müşteriler: Yakın zamanda alışveriş yapmış, sık alışveriş yapan ve yüksek harcama yapan müşteriler

Sadık müşteriler: Düzenli alışveriş yapan, orta veya yüksek harcama seviyesine sahip müşteriler



Müşteriler satın alma davranışlarına göre anlamlı segmentlere ayrılabilir.

Bu segmentler, e-ticaret işletmeleri açısından kampanya hedefleme, sadakat stratejileri, müşteri kazanımı ve müşteri kaybı riskini azaltma gibi alanlarda kullanılabilir.

6. Genel Bulgular

Çalışma sonucunda elde edilen temel bulgular şu şekildedir:

1. Toplam satış gelirinin önemli bir bölümü United Kingdom kaynaklıdır.
2. Satış gelirleri zaman içinde dalgalanma göstermektedir.
3. Sipariş tutarlarının büyük kısmı düşük ve orta seviyelerde yoğunlaşmaktadır.
4. Veri setinde az sayıda çok yüksek tutarlı sipariş bulunmaktadır.
5. Quantity ile TotalPrice arasında güçlü pozitif ilişki vardır.
6. Sipariş saati ile toplam satış tutarı arasında güçlü bir doğrusal ilişki gözlemlenmemiştir.
7. RFM analizi ve K-Means modeli ile müşteriler farklı davranış segmentlerine ayrılabilmiştir.

Bu bulgular, e-ticaret verilerinin müşteri davranışını anlamak için güçlü bir kaynak olduğunu göstermektedir.

7. Sınırlamalar

Bu çalışmanın bazı sınırlamaları bulunmaktadır.

Öncelikle veri seti yalnızca belirli bir zaman aralığını kapsamaktadır. Bu nedenle uzun dönemli müşteri davranışı veya çok yıllık trendler hakkında kesin genellemeler yapmak doğru olmayabilir.

İkinci olarak, veri seti belirli bir online perakende firmasına ait olduğu için sonuçlar tüm e-ticaret sektörünü temsil etmeyebilir. Özellikle United Kingdom verilerinin baskın olması, ülke bazlı analizlerde diğer ülkelerin etkisini daha sınırlı göstermektedir.

Üçüncü olarak, veri setinde müşteri demografik bilgileri bulunmamaktadır. Yaş, cinsiyet, gelir düzeyi veya müşteri profili gibi bilgiler olmadığı için segment yorumları yalnızca satın alma davranışına dayalı olarak yapılmıştır.

Son olarak, K-Means algoritması temel ve açıklanabilir bir yöntem olduğu için bu projede tercih edilmiştir. Ancak farklı algoritmalar veya daha kapsamlı hiperparametre optimizasyonu ile daha detaylı modeller kurulabilir.

8. Öğrenilenler

Bu proje kapsamında veri bilimi iş akışının temel aşamaları gerçek bir veri seti üzerinde uygulanmıştır. Veri yükleme, eksik veri kontrolü, aykırı değer analizi, veri tipi dönüşümleri, yeni değişken oluşturma, görselleştirme ve temel modelleme adımları deneyimlenmiştir.

Ayrıca veri analizi sürecinde grafiklerin yalnızca görsel çıktı olmadığı, aynı zamanda araştırma sorularını cevaplamak için önemli araçlar olduğu görülmüştür. Örneğin ülke bazlı gelir grafikleri pazar dağılımını, zaman serisi grafikleri satış trendlerini, histogram ve boxplot grafikleri ise sipariş tutarı dağılımını anlamaya yardımcı olmuştur.

Modelleme aşamasında RFM analizi ile müşteri davranışlarının sayısal olarak özetlenebildiği ve K-Means algoritması ile bu müşterilerin segmentlere ayrılabilirdiği görülmüştür.

9. Sonuç

Bu çalışmada UCI Online Retail veri seti kullanılarak e-ticaret müşteri davranışları analiz edilmiştir. Veri temizleme aşamasında eksik değerler, aykırı değerler ve veri tipleri incelenmiş; ardından keşifsel veri analizi ile satışların ülke, zaman, sipariş tutarı ve sayısal değişkenler açısından nasıl dağıldığı değerlendirilmiştir.

Analiz sonucunda United Kingdom'ın toplam gelir içinde en baskın ülke olduğu, satış gelirlerinin zaman içinde değişkenlik gösterdiği ve sipariş tutarlarının büyük ölçüde düşük-orta seviyelerde yoğunlaştığı görülmüştür.

Modelleme aşamasında RFM analizi ve K-Means kümeleme yöntemi kullanılarak müşteriler satın alma davranışlarına göre segmentlere ayrılmıştır. Bu segmentasyon sonucunda değerli müşteriler, sadık müşteriler, riskli müşteriler ve düşük değerli müşteriler gibi farklı müşteri grupları yorumlanabilmiştir.

Sonuç olarak, Online Retail veri seti üzerinde yapılan bu çalışma, veri bilimi iş akışının e-ticaret müşteri davranışlarını anlamada etkili biçimde kullanılabileceğini göstermektedir.